

Le code ci-dessous calcul la multiplication entre deux matrices carrées – dont la taille est passée en paramètre. Le calcul s'effectue sur le GPU à l'aide du framework JCuda. Le kernel (méthode s'effectuant sur le CPU) est dans un fichier à part.

Après avoir pris connaissance du code, répondez aux 3 questions ci-dessous en cochant les cases.

Note : il n'est pas nécessaire de comprendre l'algorithme utilisé, mais plutôt l'utilisation du GPU.

1. Quel est votre niveau d'expérience en programmation ?

Très grande expérience en programmation	1	2	3	4	5	Aucune expérience en programmation
---	---	---	---	---	---	------------------------------------

2. Quel est notre niveau d'expérience en programmation GPU ?

Très grande expérience en programmation GPU	1	2	3	4	5	Aucune expérience en programmation GPU
---	---	---	---	---	---	--

3. Comment jugez-vous la difficulté à comprendre l'utilisation du GPU dans le code ?

Très difficile à comprendre	1	2	3	4	5	Très facile à comprendre
-----------------------------	---	---	---	---	---	--------------------------

```

1 import java.util.Random;
2 import jcuda.*;
3 import jcuda.runtime.*;
4 import jcuda.driver.*;
5 import static jcuda.driver.JCudaDriver.*;
6
7 public class GPMatrix {
8
9     public static int verbose = 0; // level 0,1,2
10    public static int size;
11
12    public static void main(String[] args) {
13
14        // Params handling
15        if(args.length < 1) {
16            System.err.println("Needs size argument");
17            System.exit(0);
18        }
19        size = Integer.valueOf(args[0]);
20
21        // Matrix declaration
22        double[] A = new double[size * size];
23        double[] B = new double[size * size];
24        double[] C = new double[size * size];
25
26        matrixInit(A,B);
27
28
29        // Enable exception
30        JCudaDriver.setExceptionsEnabled(true);
31
32        // Initialize the driver and create a context for the first device
33        cuInit(0);
34        CUdevice device = new CUdevice();
35        cuDeviceGet(device, 0);
36        CUcontext context = new CUcontext();
37        cuCtxCreate(context, 0, device);
38
39        // Load the CUDA kernel ptx file
40        CUmodule module = new CUmodule();
41        cuModuleLoad(module, "../JCudaMatrix.ptx");
42
43        // Obtain a function pointer to the kernel function
44        CUfunction function = new CUfunction();
45        cuModuleGetFunction(function, module, "mul");
46

```

```

47 // Allocate the device input data, and copy the host input data
48 // to the device
49 int ptrSize = size * size * Sizeof.DOUBLE;
50 CUdeviceptr deviceInputA = new CUdeviceptr();
51 cuMemAlloc(deviceInputA, ptrSize);
52 cuMemcpyHtoD(deviceInputA, Pointer.to(A), ptrSize);
53
54 CUdeviceptr deviceInputB = new CUdeviceptr();
55 cuMemAlloc(deviceInputB, ptrSize);
56 cuMemcpyHtoD(deviceInputB, Pointer.to(B), ptrSize);
57
58 CUdeviceptr deviceOutput = new CUdeviceptr();
59 cuMemAlloc(deviceOutput, ptrSize);
60
61 // Set up the kernel parameters: A pointer to an array
62 // of pointers which points to the actual values
63 Pointer kernelParameters = Pointer.to(
64     Pointer.to(deviceInputA),
65     Pointer.to(deviceInputB),
66     Pointer.to(deviceOutput),
67     Pointer.to(new int[] {size})
68 );
69
70 // Kernel call parameters
71 int blockSizeX = 256;
72 int gridSizeX = (int) Math.ceil((double) size / blockSizeX);
73
74 // -----
75 long startTime = System.currentTimeMillis();
76 // --- Start of benchmark zone --->
77 cuLaunchKernel(function,
78     gridSizeX, 1, 1, // Grid dimension
79     blockSizeX, 1, 1, // Block dimension
80     0, null, // Shared memory size and stream
81     kernelParameters, null // Kernel and extra parameters
82 );
83 cuCtxSynchronize();
84 // <--- End of benchmark zone -----
85 long stopTime = System.currentTimeMillis();
86 // -----
87
88 // Benchmark time elapsed computation
89 long elapsedTime = stopTime - startTime;
90
91 // Output
92 if(verbose > 0) System.out.println("Time elapsed: " + elapsedTime/1000 + "s");
93 System.out.println(elapsedTime/1000);
94
95 }
96
97 // Matrix random initialization of A and B
98 public static void matrixInit(double[] A, double[] B) {
99     Random r = new Random();
100     for(int row=0; row < size; row++) {
101         for(int col=0; col < size; col++) {
102             A[ (row*size)+col ] = r.nextDouble();
103             B[ (row*size)+col ] = r.nextDouble();
104         }
105     }
106 }
107
108
109 }
110

```

Fichier contenant le kernel (méthode s'exécutant sur le GPU) :

```

1 extern "C"
2 __global__ void mul(double* A, double* B, double* C, int size) {
3     int i = blockIdx.x * blockDim.x + threadIdx.x;
4
5     if(i < size) {
6         // compute a column
7         for(int j=0; j < size; j++) {
8             double sum = 0.0;
9             for(int k=0; k < size; k++) {
10                 sum += A[ (i*size)+k ] * B[ (k*size)+j ];
11             }
12             C[ (i*size)+j ] = sum;
13         }
14         // end of column computing
15     }
16 }

```